INFORME TÉCNICO DE PROYECTO

Customer Analytics Pipeline

Cumbres Outdoor & Deporte

Análisis de comportamiento de cliente · Segmentación · Retención

Proyecto de portafolio · Data Analytics
España · 2025

Índice de contenidos

1. Introducción 3
    1.1. Presentación del cliente 3
    1.2. Problema de negocio y contexto actual 3
    1.3. Pregunta general de negocio y árbol de preguntas 3
2. Objetivos del proyecto 4
    2.1. Objetivo general 4
    2.2. Objetivos específicos 4
3. Comprensión del mercado y preparación de datos 4
    3.1. Contexto del proyecto 4
    3.2. Preguntas analíticas operativas 5
    3.3. Datos disponibles y alcance 5
    3.4 Suciedad intencional documentada 5
4. Metodología 6
    4.1 Principios metodológicos 7
5. Resultados esperados 8
    5. 1 Entregables técnicos 8
    5.2 Insights accionables esperados 8
    5.3 Base para la fase de growth analytics 8
6. Python 9
    6.1 Análisis de calidad de datos 9
    6.2 Análisis de estadística descriptiva 10
    6.3 Creación del análisis RFM 12
7. Modelado de datos en MySQL 13
    7.1 Diseño e implementación del modelo relacional 13
    7.2 Decisión de diseño: tabla tiendas como dimensión geográfica 13
    7.3 Arquitectura de datos 13
    7.4 Justificación del enfoque staging 14
    7.5 Datasets y correspondencia de tablas 14
    7.6 Modelo de Entidad-Relación 14
    7.7 Paso a paso sobre la implementación de los scripts SQL 16
    7.8 Índices análiticos 17
    7.9 Verificaciones de calidad 17
    7.10 Decisiones de diseño documentadas 18
    7.11 Tabla analítica derivada: clientes_rfm 19
8. Conexión MySQL – Power BI y Modelado en Power BI Desktop 19
    8.1 Configuración de la conexión 19
    8.2 Tablas importadas 20
    8.3 Creación de la tabla de dimensión Calendario 21
    8.4 Modelo estrella final en Power BI 21

1. Introducción

1.1. Presentación del cliente

Cumbres Outdoor & Deporte es una empresa española especializada en la venta de equipamiento deportivo y material outdoor. Opera mediante una red de cuatro tiendas físicas ubicadas en Madrid, Barcelona, Valencia y Sevilla, complementada con un canal de ecommerce propio que amplía su alcance a todo el territorio nacional.

La empresa ofrece un catálogo organizado en cuatro categorías principales: Montaña y trekking, Running y trail, Ciclismo, y Pádel. Su modelo de negocio combina la experiencia de compra en tienda, orientada al cliente que busca asesoramiento especializado, con la conveniencia del canal online.

1.2. Problema de negocio y contexto actual

Cumbres cuenta con tres años de datos transaccionales (2023–2025), pero no dispone de una estructura analítica que permita extraer valor de esa información. Las decisiones comerciales —campañas de fidelización, gestión de stock, asignación de presupuesto de marketing— se toman de forma reactiva, basadas en la intuición del equipo y en métricas agregadas de ventas, sin visibilidad sobre el comportamiento individual del cliente.

Esto genera tres problemas concretos con impacto directo en el negocio:

- Clientes valiosos sin identificar. Sin segmentación, todos los clientes reciben el mismo trato comercial, independientemente de su valor real o su potencial.
- Abandono no detectado. No existe ningún mecanismo para identificar clientes en riesgo de no volver antes de que se vayan definitivamente.
- Inversión de marketing sin criterio. Sin datos sobre el canal de adquisición más rentable ni el perfil de cliente que genera mayor valor, el presupuesto se distribuye sin optimización.

1.3. Pregunta general de negocio y árbol de preguntas

La pregunta central que orienta este proyecto es:

> *¿Quiénes son los clientes más valiosos de Cumbres, cuántos están en riesgo de abandonar la marca, y qué acciones comerciales pueden activarse para sostener el crecimiento?*

Esta pregunta se descompone en el siguiente árbol analítico:

Dimensión	Pregunta analítica	KPI asociado
Valor del cliente	¿Quiénes generan más ingresos?	Monetary (RFM) · LTV histórico
Comportamiento de compra	¿Con qué frecuencia y recencia compran?	Frequency · Recency (RFM)
Riesgo de abandono	¿Qué clientes llevan más de 90 días sin comprar?	Churn rate · días sin compra

Canal y categoría	¿Dónde y qué compran más?	Ticket medio por canal y categoría

2. Objetivos del proyecto

2.1. Objetivo general

Construir un pipeline de análisis de datos end-to-end que permita a Cumbres Outdoor & Deporte comprender el comportamiento de su base de clientes, identificar segmentos de valor y riesgo, y generar insights accionables que apoyen la toma de decisiones estratégicas de crecimiento y fidelización.

2.2. Objetivos específicos

- Generar un dataset sintético representativo con calidad de datos realista, que incluya suciedad intencional documentada para simular un entorno transaccional real.
- Ejecutar un proceso de limpieza y transformación de datos con criterio analítico documentado, diferenciando cada decisión de tratamiento según su impacto en el análisis.
- Modelar la información en un esquema dimensional (esquema estrella) que permita consultas analíticas eficientes y sea compatible con herramientas de BI.
- Calcular los KPIs de customer analytics: segmentación RFM, LTV histórico, churn y ticket medio por canal y categoría de producto.
- Construir un dashboard ejecutivo en Power BI orientado a decisiones comerciales, no a métricas técnicas, con el equipo directivo como destinatario principal.
- Documentar todas las decisiones analíticas y técnicas del proyecto para garantizar trazabilidad y reproducibilidad.

3. Comprensión del mercado y preparación de datos

3.1. Contexto del proyecto

Este proyecto parte de un escenario simulado de encargo analítico. Los datos han sido generados de forma sintética con la librería Faker en Python, replicando la estructura y calidad de datos de un sistema transaccional de retail real. El período analizado comprende tres años completos de actividad: enero de 2023 a diciembre de 2025.

El contexto de negocio asumido es el de una empresa que lleva años operando sin análisis estructurado de clientes, con datos disponibles pero sin explotar. Esta es la situación más habitual en empresas medianas del retail español, donde la prioridad ha sido operativa y la analítica de cliente se ha postergado.

3.2. Preguntas analíticas operativas

A partir del árbol de preguntas de negocio, se definen las siguientes preguntas operativas que guían el análisis:

#	Pregunta operativa	Responde a
1	¿Cuál es la distribución de clientes por segmento RFM?	Priorización de acciones por segmento
2	¿Qué porcentaje de clientes lleva más de 90 días sin comprar?	Tamaño del problema de churn
3	¿Cuál es el LTV medio por segmento RFM?	Relación entre segmento y valor generado
4	¿Qué canal de venta genera mayor ticket medio?	Eficiencia de canal físico vs. web
5	¿Qué categoría tiene mayor valor por transacción?	Optimización de mix de producto
6	¿Cómo evoluciona la actividad de compra a lo largo del tiempo?	Estacionalidad y tendencia de ventas

3.3. Datos disponibles y alcance

El proyecto trabaja con cuatro entidades de datos que forman el núcleo mínimo necesario para el análisis de customer analytics:

Entidad	Registros	Campos clave	Uso analítico
Clientes	1.000	customer_id, canal_adquisicion, fecha_alta, ciudad	Base de segmentación RFM y churn
Transacciones	8.000	customer_id, importe, fecha, store_id, product_id	Cálculo de R, F, M y LTV
Productos	48	product_id, categoria, precio_base	Ticket medio por categoría
Tiendas	5	store_id, ciudad (T05 = web)	Ticket medio por canal

3.4 Suciedad intencional documentada

Los datos incluyen imperfecciones controladas que simulan la calidad real de un sistema transaccional de retail. Cada tipo de suciedad tiene una causa de negocio documentada y un tratamiento previsto en la fase de limpieza:

Tipo	Campo afectado	Vol.	Causa simulada	Tratamiento previsto

Nulos	clientes.email	4%	Clientes registrados en tienda sin email	Mantener nulo; no imputable
Nulos	clientes.ciudad	5%	Campo no obligatorio en formulario web	Mantener nulo; excluir de análisis geográfico
Nulos	transacciones.store_id	3%	Transacciones web sin tienda asignada	Imputar T05 (canal web)
Outliers	transacciones.importe	2%	Error de terminal POS (importe ×8)	Filtrar por umbral IQR
Negativos	transacciones.importe	1%	Devoluciones mal registradas	Excluir del análisis de ventas

4. Metodología

El proyecto sigue una metodología de pipeline de datos estructurado en cinco fases secuenciales. Cada fase tiene entradas definidas, transformaciones documentadas y salidas concretas. Este enfoque garantiza trazabilidad completa desde el dato bruto hasta el insight accionable.

Fase	Nombre	Actividades principales	Herramientas	Entregable
01	**Generación de datos**	Creación de datos sintéticos con suciedad intencional. Diseño de entidades y relaciones. Documentación de decisiones de diseño.	Python · faker · numpy · pandas	4 CSV en data/raw/ · generate_cumbres.py
02	**Limpieza y transformación**	Exploración inicial (EDA). Tratamiento de nulos, outliers y fechas inconsistentes. Normalización de formatos. Validación de integridad.	Python · pandas · Jupyter Notebook	4 CSV limpios en data/clean/ · notebook 02_limpieza.ipynb
03	**Modelado de datos**	Diseño del esquema estrella. Creación de tablas dimensionales y tabla de hechos. Validación de integridad referencial.	SQL · SQLite · Python	Base de datos cumbres.db · notebook 03_modelado.ipynb
04	**Análisis de KPIs**	Cálculo de RFM por cliente. LTV histórico por segmento. Identificación de	SQL · Python · pandas	Tablas de KPIs en data/processed/ · notebook 04_kpis.ipynb

Fase	Nombre	Actividades principales	Herramientas	Entregable
		clientes en churn. Ticket medio por canal y categoría.		
05	**Dashboard ejecutivo**	Diseño de visualizaciones orientadas a decisiones. Conexión a datos procesados. Publicación del informe visual.	Power BI · DAX	Archivo .pbix · Dashboard interactivo

4.1 Principios metodológicos

En un entorno productivo, los datasets utilizados en este proyecto provendrían de dos sistemas principales:

- ERP (Enterprise Resource Planning): Los datos de 'transacciones', 'productos' y 'tiendas' se extraerán de un ERP, que es el sistema donde se registran las ventas, devoluciones, catálogo de productos y estructura de puntos de venta. Ejemplos comunes: SAP, Oracle,Microsoft Dynamics.

- CRM (Customer Relationship Management): Los datos de 'clientes' 'registro de clientes', 'canal de adquisición' y 'fecha de alta' provienen típicamente de un CRM, que es el sistema encargado de gestionar la relación con el cliente. Ejemplos comunes: Salesforce, HubSpot, Zoho.

El flujo real sería:

ERP + CRM → extracción vía API o exportación CSV → Python (limpieza) → MySQL (análisis) + Power BI (visualización)

La metodología aplicada en este proyecto: exploración, limpieza y documentación de decisiones replica exactamente ese flujo, con la diferencia de que los datos fueron generados sintéticamente en vez de extraídos de un sistema real.

Por lo tanto, se llevarán a cabo las siguientes acciones:

- Separación de datos raw y clean. Los datos originales nunca se modifican. Todo el proceso de limpieza genera nuevos archivos en carpetas separadas, garantizando la reproducibilidad completa.
- Decisiones documentadas. Cada elección técnica: qué hacer con un nulo, qué umbral usar para outliers, qué granularidad para el RFM, se registra en docs/decisiones.md con su justificación de negocio.
- Criterio antes que ejecución. El valor analítico no está en ejecutar el código, sino en las decisiones que lo preceden. Este informe es parte del entregable porque documenta el pensamiento detrás del pipeline.
- Orientación a acción. Cada KPI calculado está vinculado a una decisión comercial posible. El análisis descriptivo es el punto de partida, no el destino.

5. Resultados esperados

Al finalizar el proyecto, Cumbres Outdoor & Deporte dispondrá de una base analítica estructurada y de un conjunto de insights accionables que permitan orientar decisiones comerciales concretas. Los resultados se organizan en tres niveles:

5. 1 Entregables técnicos

Entregable	Descripción
generate_cumbres.py	Script de generación de datos sintéticos, documentado y reproducible
data/clean/*.csv	Datos limpios y normalizados, listos para análisis
cumbres.db	Base de datos SQLite con esquema estrella y datos cargados
notebooks 01–04	Jupyter Notebooks con el análisis completo y comentado
data/processed/*.csv	Tablas de KPIs: segmentos RFM, LTV, churn, ticket medio
Dashboard .pbix	Informe visual interactivo en Power BI
docs/decisiones.md	Log de decisiones analíticas con justificación de negocio
README.md	Documentación completa del proyecto para GitHub

5.2 Insights accionables esperados

Los análisis producirán respuestas concretas a las preguntas de negocio planteadas. Se espera obtener los siguientes tipos de insights:

- Identificación del segmento de clientes de alto valor (Champions en terminología RFM): clientes con compra reciente, alta frecuencia y alto gasto. Este grupo representa la base más rentable y debe recibir tratamiento diferenciado en campañas de fidelización.
- Cuantificación del riesgo de churn: porcentaje de clientes sin compra en los últimos 90 días, desglosado por ciudad y canal de adquisición. Permite dimensionar el problema y priorizar acciones de reactivación.
- Comparativa de ticket medio entre canal físico y web: determina si la experiencia de compra en tienda genera transacciones de mayor valor, lo que tiene implicaciones directas sobre la estrategia de expansión de red física vs. inversión en ecommerce.
- Ranking de categorías por valor por transacción: identifica qué líneas de producto (Montaña, Running, Ciclismo, Pádel) generan mayor ingreso por compra, orientando decisiones de mix de producto y espacios en tienda.

5.3 Base para la fase de growth analytics

Este proyecto de customer analytics sienta las bases para una fase posterior de growth analytics. Los datos de canal de adquisición ya están incorporados en el dataset, lo que

permitirá en una segunda fase calcular el ratio CAC:LTV por canal, construir curvas de retención por cohorte y modelar escenarios de crecimiento bajo distintas hipótesis de inversión en adquisición.

La secuencia correcta es la que se ha seguido aquí: primero entender quién es el cliente y cómo se comporta, y después analizar qué palancas de adquisición y crecimiento maximizan el valor generado. Un análisis de growth sin esta base tiende a optimizar métricas de adquisición sin saber qué tipo de cliente se está adquiriendo ni cuánto vale realmente.

6. Python

Para llevar a cabo el análisis y responder las preguntas operativas, se construyeron cuatro datasets sintéticos con fines académicos: `tiendas`, `productos`, `clientes` y `transacciones`. Los datos fueron generados mediante scripts de Python desarrollados con asistencia de Claude (Anthropic) y ejecutados en Jupyter Notebook sobre Anaconda. La estructura de cada dataset fue diseñada para representar una cadena de tiendas físicas con canal web, manteniendo coherencia entre las tablas a través de claves comunes.

De forma intencional, se introdujeron datos sucios en algunos campos para simular problemas reales de calidad. El objetivo fue poder practicar la exploración y limpieza de datos de manera realista: aprender a detectar patrones, cuestionar cada valor ausente y tomar decisiones fundamentadas antes de tocar los datos.

6.1 Análisis de calidad de datos

Se analizaron los 4 datasets del proyecto antes de iniciar cualquier transformación. Solo dos presentaron valores nulos con decisiones a tomar: `clientes` y `transacciones`. Los datasets `productos` y `tiendas` no registraron ausencias.

El criterio metodológico aplicado en todos los casos siguió el mismo orden: primero determinar si el campo participa en alguna de las 6 preguntas operativas del proyecto, luego analizar si los nulos tienen un origen sistémico o son ruido aleatorio, y finalmente decidir en consecuencia. Este orden es deliberado, si el campo no entra en el análisis, el tratamiento del nulo no afecta los resultados independientemente de su patrón.

En el dataset `clientes`, los campos `email` y `ciudad` presentaron 39 y 50 nulos respectivamente. El análisis de solapamiento, canal de adquisición y temporalidad confirmó que los nulos son aleatorios, independientes entre sí y sin concentración en ningún canal ni período. Dado que ninguna de las dos columnas participa en las preguntas operativas, se decidió conservar los nulos y preservar las 89 filas afectadas con toda su información de transacciones, canal y fecha de alta.

En el dataset `transacciones`, el campo `store_id` presentó 240 nulos (3%). A diferencia del caso anterior, este campo participa directamente en la pregunta operativa 4 -canal de

venta con mayor ticket medio- por lo que requería tratamiento. El análisis temporal descartó un error puntual de sistema dado que los nulos aparecen de forma uniforme a lo largo de 3 años, y el ticket medio de los registros afectados (220.35) resultó coherente con el canal web (T05 · Cumbres Web · 236.30). Se imputó el valor T05 documentando que se trata de una asunción basada en evidencia circunstancial, apropiada para el contexto de datos simulados.

Como resultado, no se eliminó ninguna fila del dataset original. La integridad de los 9.000 registros se preserva íntegramente.

6.2 Análisis de estadística descriptiva

6.2.1 Variables numéricas

En importe:

- Existen valores negativos. El mínimo es -2378.40, lo cual es una señal importante. En un contexto de ventas los importes negativos típicamente representan devoluciones o abonos, no errores. Pero hay que verificar cuántos son y si tienen algún patrón.
- La media y la mediana están separadas. Media 233 vs mediana 210, hay sesgo hacia la derecha, lo que sugiere algunos importes altos que tiran de la media. El máximo de 3.198 vs el percentil 75 de 308 confirma que hay transacciones de ticket muy alto.

En cantidad: se ve limpia

- Rango de 1 a 3, sin valores imposibles. Sin nada que investigar aquí.

6.2.2 Tratamiento de valores negativos

Para poder dar cuenta de la situación de los valores negativos se observa el siguiente campo **: importe ,** reúne 80 registros negativos (1% de 8.000 transacciones).

Análisis previo a la decisión

Se identificaron 80 transacciones con importe negativo, con una media de -257.53 y un mínimo de -2378.40. Antes de decidir su tratamiento se verificó su distribución por tienda:

Tienda	Negativos	% sobre su total
T01 · Madrid	18	1.18%
T02 · Barcelona	15	0.98%
T03 · Valencia	18	1.21%
T04 · Sevilla	15	0.92%
T05 · Web	14	0.76%

Interpretación: transacciones negativas (devoluciones)

Se registraron 80 devoluciones, representando el 1% del total de transacciones. Los importes devueltos oscilan entre 21 y 2.378, con un promedio de 257.

La dispersión es alta : la desviación estándar (356) supera a la media (257), lo que indica que las devoluciones no son homogéneas: conviven devoluciones de tickets pequeños con devoluciones de alto valor.

La distribución por tienda es uniforme, entre 0.76% y 1.21% en todos los canales, lo que confirma que se trata de un comportamiento natural del negocio y no de un problema localizado en ningún canal específico.

Conclusión del análisis

La distribución es uniforme entre todas las tiendas, sin concentración en ningún canal ni tienda específica. El volumen (1%) es coherente con una tasa de devolución normal en retail. No se identificaron patrones que sugieran errores de registro.

Decisión[1]

Se conservan los 80 registros negativos sin modificación, ya que representan devoluciones legítimas dentro del ciclo de venta. Excluirlos daría una imagen artificialmente positiva del valor del cliente, se estaría midiendo lo que compra, no lo que realmente aporta al negocio.

Conservar los negativos permite que el LTV refleje el comportamiento completo del cliente: compras menos devoluciones. Esto es especialmente relevante para la pregunta operativa 3: *¿cuál es el LTV medio por segmento RFM?*

6.2.3 Tratamiento de valores positivos (outliers)

El campo que se observó para poder llevar a cabo el tratamiento de los valores positivos fue el siguiente: **importe** . El cual reúne 80 registros por encima del percentil 99 (1.583).

Análisis previo a la decisión

La distribución por percentiles mostró una progresión gradual hasta el percentil 95 (387) seguida de un salto brusco al percentil 99 (1.583) y al máximo (3.198). Se analizaron los 80 registros afectados:

Métrica	Valor
Media	**2.446**
Desviación estándar	**476**

[1] Nota:estos registros fueron originalmente diseñados como devoluciones mal registradas a excluir del análisis. Sin embargo, dado que su distribución es uniforme entre canales y representan el comportamiento real de devolución del negocio, se tomó la decisión de conservarlos para reflejar el valor neto real del cliente en el cálculo del LTV.

Mínimo	**1.587**
Máximo	**3.198**

La distribución por tienda resultó uniforme, entre 13 y 21 registros por canal, con T05 · Web levemente por encima, lo cual es coherente con un canal sin fricción geográfica que puede atraer tickets más altos.

Conclusión del análisis

El campo `cantidad` de estos registros se mantiene en el rango 1-3, idéntico al resto del dataset. No hay señal de error de registro — son transacciones de alto valor legítimas, posiblemente asociadas a categorías de producto de precio elevado.

Decisión

Se conservan los 80 registros sin modificación. Excluirlos distorsionaría el LTV real de los clientes de alto valor, que son precisamente los más relevantes para la segmentación RFM y la pregunta operativa 3 : *¿cuál es el LTV medio por segmento RFM?.*

6.3 Creación del análisis RFM

Para responder a las preguntas operativas del proyecto, se construyó un modelo RFM (Recencia, Frecuencia, Monetario) que permite segmentar a los clientes según su comportamiento de compra y analizar su valor.

El cálculo se realizó en Python debido a su flexibilidad para el análisis exploratorio, permitiendo definir los percentiles y criterios de segmentación en función de la distribución real de los datos, así como garantizar la trazabilidad y reproducibilidad del proceso.

Como resultado, se generó un nuevo dataset con las métricas RFM y la variable `segmento_rfm`, el cual fue exportado como archivo independiente para su incorporación en el modelo de MySQL en la siguiente etapa del proyecto, y posterior análisis en Power BI.

6.3.1 Normalizar nombres de columnas y agregar fecha_calculo

Antes de exportar el CSV se aplican dos ajustes finales:

- Normalización de nombres de columnas a minúscula mediante `df_rfm.columns.str.lower()`, garantizando consistencia exacta con los nombres de campo definidos en MySQL y evitando errores en la carga con `LOAD DATA INFILE`.
- Incorporación de la columna `fecha_calculo` con la fecha del día de ejecución, para registrar cuándo fue generado el modelo RFM. Esta columna permite trazabilidad en futuras actualizaciones: si se incorporan nuevos datos de transacciones y se recalcula el modelo, `fecha_calculo` identifica a qué corte temporal corresponde cada versión de los segmentos.

6.3.2 Exportación CSV

- Archivo: `clientes_rfm.csv`
- Columnas: `customer_id`, `recencia`, `frecuencia`, `monetario`, `segmento_rfm`, `churn_riesgo`, `fecha_calculo`
- Listo para carga en MySQL y consumo en Power BI

7. Modelado de datos en MySQL

7.1 Diseño e implementación del modelo relacional

Esta fase comprende el diseño e implementación del modelo relacional en MySQL a partir de los cuatro datasets sintéticos limpios generados en la fase anterior de EDA y limpieza. El objetivo es construir una base de datos relacional que soporte las consultas analíticas necesarias para responder a las preguntas operativas del proyecto.

7.2 Decisión de diseño: tabla tiendas como dimensión geográfica

La tabla tiendas cumple un doble rol en el modelo: como dimensión de integridad referencial (garantizando que toda transacción apunta a una tienda válida) y como dimensión geográfica para el dashboard en Power BI. En lugar de implementar la pregunta 7 como una consulta estática, tiendas.ciudad se utilizará como campo de segmentador (slicer) en Power BI, permitiendo filtrar dinámicamente todos los KPIs del dashboard por ciudad de tienda.

7.3 Arquitectura de datos

La carga de datos sigue una arquitectura de dos capas: tablas staging sin restricciones para la ingesta inicial de los CSV, seguidas de tablas finales con claves primarias, claves foráneas e índices analíticos. Esta arquitectura permite separar la fase de ingesta (tolerante a errores de tipo y formato) de la fase de validación y transformación.

CSV limpios → Tablas staging (sin restricciones) → INSERT SELECT con conversión de tipos → Tablas finales (PK + FK + índices)

La implementación se divide en cuatro scripts SQL numerados secuencialmente, ejecutados en orden estricto:

- Script 01 — Crear base de datos y tablas staging
- Script 02 — Carga de CSV a tablas staging mediante LOAD DATA INFILE
- Script 03 — Crear tablas finales con PK, FK e índices analíticos
- Script 04 — Migración de staging a tablas finales con conversión de tipos

7.4 Justificación del enfoque staging

Utilicé Mysql Server 9,4, el cual impone restricciones de seguridad sobre LOAD DATA LOCAL INFILE que impiden la carga directa con tipos estrictos. La solución correcta es ingestar todo como VARCHAR en staging (sin restricciones), validar los recuentos de filas, y aplicar la conversión de tipos en el INSERT SELECT hacia las tablas finales. Esto también facilita el diagnóstico de errores de formato en los datos de origen.

7.5 Datasets y correspondencia de tablas

Tabla staging	Tabla final	Filas esperadas	Origen
stg_tiendas	tiendas	5	tiendas_clean.csv
stg_clientes	clientes	1.000	clientes_clean.csv
stg_productos	productos	48	productos_clean.csv
stg_transacciones	transacciones	8.000	transacciones_clean.csv

> *Los CSV limpios se copiaron manualmente a la carpeta segura del servidor MySQL antes de ejecutar el Script 02: C:\ProgramData\MySQL\MySQL Server 9.4\Uploads*

7.6 Modelo de Entidad-Relación

El modelo sigue un esquema en estrella simplificado con una tabla de hechos central (transacciones) y tres tablas de dimensión (clientes, productos, tiendas). Todas las relaciones son de tipo muchos a uno desde la tabla de hechos hacia las dimensiones.

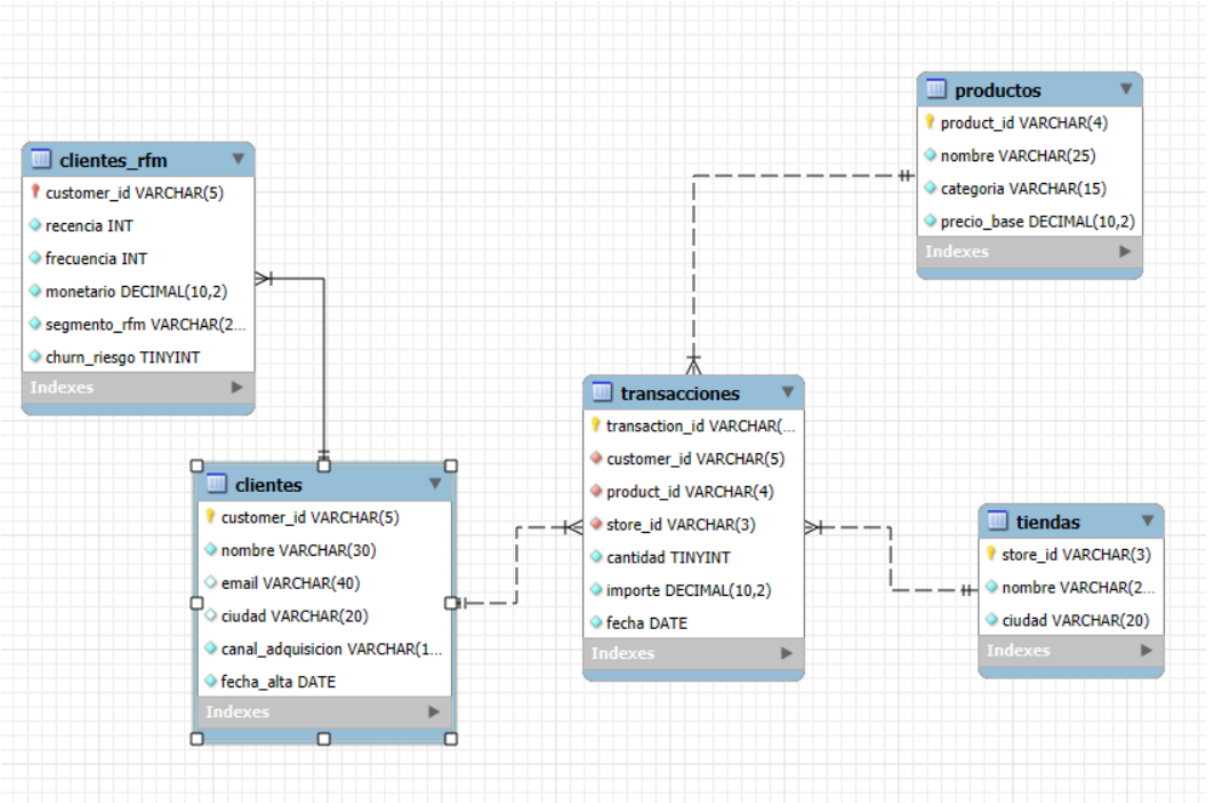

7.6.1 Tabla de hechos

transacciones

Registra cada transacción de compra o devolución. Contiene tres claves foráneas hacia las dimensiones y los campos de medida necesarios para los análisis RFM, LTV y tendencia temporal.

- transaction_id VARCHAR(7) — clave primaria
- customer_id VARCHAR(5) — FK → clientes
- product_id VARCHAR(4) — FK → productos
- store_id VARCHAR(3) — FK → tiendas
- cantidad TINYINT — unidades por transacción
- importe DECIMAL(10,2) — importe de la transacción; valores negativos representan devoluciones (documentado como dato válido)
- fecha DATE — fecha de la transacción

7.6.2 Tablas de dimensiones

clientes

- customer_id VARCHAR(5) — clave primaria
- nombre VARCHAR(30)
- email VARCHAR(40) NULL — ~4% de nulos, ruido aleatorio documentado en EDA
- ciudad VARCHAR(20) NULL — ~5% de nulos, ruido aleatorio documentado en EDA
- canal_adquisicion VARCHAR(10) — canal de captación del cliente
- fecha_alta DATE

productos

- product_id VARCHAR(4) — clave primaria
- nombre VARCHAR(25)
- categoria VARCHAR(15)
- precio_base DECIMAL(10,2)

tiendas

- store_id VARCHAR(3) — clave primaria
- nombre VARCHAR(20)
- ciudad VARCHAR(20) — campo usado como dimensión geográfica en Power BI

7.6.3 Claves foráneas e integridad referencial

Las tres FK de la tabla de hechos garantizan integridad referencial a nivel de base de datos:

- fk_trans_cliente: transacciones.customer_id → clientes.customer_id
- fk_trans_producto: transacciones.product_id → productos.product_id

- fk_trans_tienda: transacciones.store_id → tiendas.store_id

> *Las FK se definen en la tabla transacciones (tabla de hechos), no en las dimensiones. El orden de inserción obligatorio es: dimensiones primero (tiendas, clientes, productos), tabla de hechos al final.*

7.7 Paso a paso sobre la implementación de los scripts SQL

7.7.1 Script 01- Creación de base de datos y tablas staging

Crea la base de datos customer_analytics con codificación utf8mb4 y las cuatro tablas staging. Todas las columnas son VARCHAR para garantizar compatibilidad con cualquier formato de origen sin que MySQL rechace filas por incompatibilidad de tipos.

```
CREATE DATABASE IF NOT EXISTS customer_analytics
  CHARACTER SET utf8mb4 COLLATE utf8mb4_unicode_ci;
```

La verificación al final del script comprueba que las cuatro tablas stg_* han sido creadas correctamente consultando information_schema.tables.

7.7.2 Script 02 - Carga de CSV a staging

Utiliza LOAD DATA INFILE (ruta absoluta al directorio seguro del servidor) para cargar los cuatro CSV limpios. Antes de cada carga se ejecuta TRUNCATE para permitir re-ejecución segura del script. Se especifica CHARACTER SET utf8mb4, separador de campos por coma, campos opcionalmente entre comillas dobles, y salto de línea \r\n.

> *Condición previa: los CSV deben copiarse manualmente a C:\ProgramData\MySQL\MySQL Server 9.4\Uploads\ antes de ejecutar este script. Esta ruta es la determinada por la variable secure_file_priv en MySQL 9.4.*

Recuentos esperados tras la carga: stg_tiendas = 5 filas, stg_clientes = 1.000, stg_productos = 48, stg_transacciones = 8.000.

7.7.3 Script 03 - Creación de tablas finales

Crea las cuatro tablas finales con los tipos de datos definitivos, claves primarias, claves foráneas e índices analíticos. Se ejecuta con FOREIGN_KEY_CHECKS = 0 durante el DROP inicial para evitar errores de dependencia de FK en caso de re-ejecución.

El orden de creación es obligatorio: primero las tres dimensiones (tiendas, clientes, productos) y después la tabla de hechos (transacciones), ya que esta última referencia las PK de las tres anteriores.

7.7.4 Script 04 - Migración staging → tablas finales

Ejecuta los INSERT SELECT que migran los datos de staging a las tablas finales aplicando las transformaciones de tipo necesarias. El orden de inserción sigue la misma lógica que la creación: dimensiones primero, hechos al final.

Transformaciones de tipo aplicadas:

Campo	Tipo staging	Tipo final	Transformación aplicada
fecha_alta	VARCHAR(20)	DATE	STR_TO_DATE(..., '%Y-%m-%d')
email	VARCHAR(100)	VARCHAR(40) NULL	NULLIF(TRIM(email), '')
ciudad (clientes)	VARCHAR(100)	VARCHAR(20) NULL	NULLIF(TRIM(ciudad), '')
precio_base	VARCHAR(20)	DECIMAL(10,2)	CAST(REPLACE(..., ',', '.') AS DECIMAL)
cantidad	VARCHAR(10)	TINYINT	CAST(TRIM(cantidad) AS SIGNED)
importe	VARCHAR(20)	DECIMAL(10,2)	CAST(REPLACE(..., ',', '.') AS DECIMAL) — negativos conservados
fecha (transacc.)	VARCHAR(20)	DATE	STR_TO_DATE(..., '%Y-%m-%d')

> *Los valores negativos de importe se conservan intencionalmente como devoluciones legítimas, decisión documentada en la fase de EDA. Los outliers superiores al percentil 99 también se conservaron por el mismo motivo.*

7.8 Índices analíticos

Se crearon cuatro índices adicionales sobre los campos más frecuentemente usados en filtros y agrupaciones analíticas. Estos índices no afectan a la integridad del modelo pero mejoran el rendimiento de las consultas operativas.

Índice	Tabla / Campo	Propósito analítico
idx_trans_fecha	transacciones.fecha	Filtrado y agrupación temporal (P6, P7)
idx_trans_store	transacciones.store_id	Join con tiendas para análisis geográfico (P7)
idx_cli_canal	clientes.canal_adquisicion	Segmentación por canal (P4, Growth fase 2)
idx_prod_categoria	productos.categoria	Agrupación por categoría de producto (P5)

7.9 Verificaciones de calidad

7.9.1 Verificación de recuentos

Al final de cada script se incluyen queries de verificación. El resultado esperado tras la ejecución completa del pipeline es:

- tiendas: 5 filas
- clientes: 1.000 filas
- productos: 48 filas
- transacciones: 8.000 filas

7.9.2 Verificación de integridad referencial

El Script 04 incluye tres LEFT JOIN de diagnóstico que comprueban que ninguna transacción apunta a un customer_id, product_id o store_id inexistente en la dimensión correspondiente. El resultado esperado es 0 en los tres checks.

```
SELECT 'FK cliente sin match', COUNT(*)
FROM transacciones t LEFT JOIN clientes c ON t.customer_id = c.customer_id
WHERE c.customer_id IS NULL;
```

7.9.3 Limpieza de staging

Una vez validada la carga completa, las tablas staging pueden eliminarse mediante los DROP TABLE comentados al final del Script 04. Esta operación es irreversible y solo debe ejecutarse cuando se confirma que las tablas finales contienen los recuentos correctos y pasan los checks de integridad referencial.

7.10 Decisiones de diseño documentadas

- **Nulos en email y ciudad de clientes.** Se definen como NULL en la tabla final (no como cadena vacía). La conversión NULLIF(TRIM(campo), '') en el Script 04 garantiza que las cadenas vacías del staging quedan como NULL en la tabla final. Decisión alineada con el análisis de EDA.

- **Importe negativo en transacciones.** Los valores negativos representan devoluciones y se conservan como dato válido. No son errores de carga.

- **Imputación de store_id nulo.** Los registros de transacciones con store_id nulo fueron imputados con el valor T05 durante la fase de limpieza en Python, basándose en uniformidad temporal y coherencia del ticket medio. Esta decisión está documentada como inferencia circunstancial apropiada para datos sintéticos.

- **canal_adquisicion a nivel de cliente.** El campo modela el canal de captación del cliente, no el canal de cada transacción individual. Esta es la lectura correcta para el análisis de customer analytics y queda como input para la fase de growth analytics.

- **tiendas como dimensión geográfica en Power BI.** La pregunta operativa 7 no se implementa como una consulta estática sino como un slicer en Power BI usando tiendas.ciudad, lo que permite filtrar dinámicamente todos los KPIs del dashboard por ciudad de tienda.

7.11 Tabla analítica derivada: clientes_rfm

Una vez validado el modelo relacional y verificada la integridad de las cuatro tablas finales, se incorporó una tabla adicional de resultados analíticos: `clientes_rfm`.

Esta tabla no forma parte del modelo relacional operacional. Es el resultado del cálculo RFM ejecutado en Python sobre los datos de `transacciones`, exportado como `clientes_rfm.csv` y persistido en MySQL mediante `LOAD DATA INFILE`, siguiendo el mismo procedimiento de carga utilizado para las tablas del modelo relacional. Su inclusión en la base de datos responde a una decisión de eficiencia analítica: el modelo RFM requiere clasificar a cada cliente por quintiles en relación al conjunto completo, una operación de segmentación relativa que resulta compleja en SQL y no es apropiada como medida DAX, ya que se recalcularía en cada consulta del dashboard. Calcularlo una vez en Python y persistir el resultado garantiza que las preguntas operativas P1 (segmentación RFM), P2 (churn) y P3 (LTV por segmento) se respondan con datos ya procesados, sin trasladar lógica de transformación a la capa de visualización.

Se relaciona con `clientes` mediante una FK 1:1 sobre `customer_id`, actuando como enriquecimiento del perfil del cliente con atributos de comportamiento calculado. La tabla se considera regenerable: debe recalcularse en Python y reexportarse como `clientes_rfm.csv` cada vez que se actualice el conjunto de transacciones.

Verificación de carga: 2026-04-09

Métrica	Resultado
Total clientes RFM	1.000
Clientes en riesgo de churn	502
Fecha de cálculo	2026-04-09

Los 1.000 registros coinciden exactamente con el total de clientes de la dimensión `clientes`, confirmando que la FK 1:1 es consistente y no hay clientes sin segmento asignado.

8. Conexión MySQL – Power BI y Modelado en Power BI Desktop

8.1 Configuración de la conexión

Para establecer la conexión entre MySQL Server 9.4 y Power BI Desktop (v2.151.1052.0, 64-bit), se utilizó el conector MySQL Connector/ODBC 8.0 como puente de comunicación, dado que Power BI no soporta versiones del Connector/NET superiores a la 8.0.x.

El proceso de configuración consistió en los siguientes pasos:

- Descarga e instalación del driver MySQL ODBC 8.0 Unicode Driver (64-bit) desde el repositorio oficial de MySQL.

- Creación de un DSN de sistema (Data Source Name) denominado mysql_powerbi mediante el Administrador de orígenes de datos ODBC (64 bits), con los siguientes parámetros:

Parámetro	Valor
Server	localhost
User	root
Database	customer_analytics
Driver	MySQL ODBC 8.0 Unicode Driver

- Verificación de la conexión mediante el botón Test, obteniendo resultado Connection successful.
- Importación de las cuatro tablas finales del modelo relacional desde Power BI Desktop mediante Obtener datos → ODBC → mysql_powerbi.

8.2 Tablas importadas

Se importaron las siguientes tablas al modelo de Power BI:

- clientes
- transacciones
- productos
- tiendas
- clientes_rfm (tabla analítica)

Power BI detectó automáticamente las relaciones entre tablas a partir de las claves primarias y foráneas definidas en MySQL, replicando el modelo relacional construido en la fase anterior.

8.3 Creación de la tabla de dimensión Calendario

Como buena práctica de modelado en Power BI, se creó una tabla de dimensión de tiempo mediante DAX, siguiendo el estándar profesional de no depender únicamente de las columnas de fecha nativas de las tablas de hechos. La tabla Calendario se generó con el siguiente código DAX:

```
Calendario =
VAR FechaInicio = MIN(transacciones[fecha])
VAR FechaFin = MAX(transacciones[fecha])
RETURN
ADDCOLUMNS(
        CALENDAR(FechaInicio, FechaFin),
        "Año", YEAR([Date]),
        "Trimestre", "T" & QUARTER([Date]),
        "Mes_Numero", MONTH([Date]),
        "Mes_Nombre", FORMAT([Date], "MMMM", "es-ES"),
        "Semana", WEEKNUM([Date], 2),
        "Dia_Semana_Numero", WEEKDAY([Date], 2),
        "Dia_Semana_Nombre", FORMAT([Date], "DDDD", "es-ES"),
        "Es_Fin_De_Semana", IF(WEEKDAY([Date], 2) >= 6, "Si", "No"),
        "Año_Mes", FORMAT([Date], "YYYY-MM")
)
```

El rango de fechas se calcula dinámicamente a partir de los valores mínimo y máximo de la columna fecha de la tabla transacciones, garantizando que el calendario se adapte automáticamente al período cubierto por los datos.

8.4 Modelo estrella final en Power BI

Se estableció la relación entre la tabla Calendario y la tabla de hechos transacciones mediante Calendario[Date] → transacciones[fecha] con cardinalidad uno a muchos (1:*), completando un modelo estrella con las siguientes relaciones activas:

Tabla dimensión	Clave	Tabla de hechos	Clave	Cardinalidad
Calendario	Date	transacciones	fecha	1:*
clientes	customer_id	transacciones	customer_id	1:*
productos	product_id	transacciones	product_id	1:*
tiendas	store_id	transacciones	store_id	1:*

Este modelo garantiza una navegación eficiente entre dimensiones y hechos, y constituye la base sobre la que se construirán todas las visualizaciones analíticas del proyecto.